

可视化实验指导



可视化实验指导

（第 2025-2026-1 版）

任课教师：曾琼（qiong.zn@sdu.edu.cn）

助教：张景赫（1791216214@qq.com）

王文嵩（wangwensong@mail.sdu.edu.cn）

王阳（1766897491@qq.com）

目录

可视化实验指导.....	1
一、可视化设计.....	2
1.1 实验目标	3
1.2 数据集	3
1.3 实验步骤以及示例代码	3
1.3.1 设计思路.....	3
1.3.2 代码.....	3
1.3.3 结果展示.....	3
二、欺骗性可视化.....	4
2.1 实验目标	4
2.2 数据集选取	4
2.3 实验步骤及代码	4
2.3.1 数据集选取.....	5
2.3.2 设计思路.....	5
2.3.3 代码.....	5
2.3.4 结果展示.....	5
2.3.5 结论.....	6
三、降维	6
3.1 实验目标	6
3.2 实验步骤	7
3.2.1 数据集选取.....	7
3.2.3 结果展示.....	7
四、可视化设计-可视化相互交织的树木.....	11
4.1 实验目标	11
4.2 数据选取	11
4.3 实验步骤	12
4.3.1 设计的可视化方法.....	12
4.3.2 结果展示.....	12
4.3.3 实验优缺点.....	12
五、可视化网络数据.....	13
5.1 实验目标	13
5.2 实验步骤	13
5.2.1 数据集.....	13
5.2.2 设计思路.....	13
5.2.3 结果展示.....	14

一、可视化设计

1.1 实验目标

在此任务中，您将为一个数据集设计一个可视化，并为您的设计选择提供严格的理由。在理论上，你应该准备好解释显示器中每个像素的贡献。您可以使用 D3 或 Vega/Vega-lite，包括手工起草。但是，您可能会发现使用您选择的图形 API 从头开始创建图表最有指导意义。

截止日期：2025.9.21

提交地址：[实验 1 文件夹下](#)

1.2 数据集

每 10 年，人口普查局记录美国的人口构成，影响从国会选区到社会服务的一切。该数据集包含了两个世纪之间的两年的人口普查数据的高级摘要：1900 年和 2000 年。该数据是一个 CSV（逗号分隔值）文件，描述了美国人口的年份、性别（1：男性，2：女性），年龄组（从 0-4 岁到 90+ 岁），以及每组的人口总数。每年有 38 个数据点，共计 76 个数据点。

[数据集下载](#)

1.3 实验步骤以及示例代码


1.3.1 设计思路

人口金字塔是一种用于表示某个时间点的年龄直方图，可以反映一个地区的男女比例和人口的年龄构成。这种表示法显示了年龄和性别数据，这是一个直接清晰地了解人口构成的图表，可以在很大程度上利用数据集的信息。此外，粉色和蓝色通常代表女性和男性，所以我用这两种颜色作为性别划分。此外，子图的宽高比为 3:2，这是一个美学比率。

不幸的是，在我的可视化设计中，它只能显示每个年龄组的大致比例，而不能显示确切的比例。

[1.3.2 代码](#)

1.3.3 结果展示



二、欺骗性可视化

2.1 实验目标

随着可视化在公众如何消费新闻和信息中扮演越来越多的角色，认识到可视化设计如何影响查看者对数据的结论和记忆是很重要的。在此分配中，您将识别感兴趣的数据集，并设计两个静态可视化来通信数据。一种设计是对数据的真实表示，而另一种设计则是一种欺骗性的可视化，旨在误导观众。对于第二幅图像，设计的挑战是在不使用明显扭曲或遗漏的情况下误导。

截止日期：2025.10.12

提交地址：[实验 2 文件夹下](#)

2.2 数据集选取

为了快速启动并运行此任务，我们建议使用以下提供的数据集或源之一，但您可以自由使用您选择的任何数据集。这两种可视化必须使用相同的数据集，但是您可以以不同的方式转换数据，或者选择为每个设计解决不同的问题。这些数据集被有意地选择来涵盖具有政治色彩的主题，原因很简单，即这些主题通常是欺骗性可视化可能会扩散的数据类型。

- [The World Bank Data, 1960-2018](#)
- [Greenhouse Gas Emissions, 1990-2019](#)
- [DEA Pain Pills Database](#)

2.3 实验步骤及代码

2.3.1 数据集选取

美国各州新冠肺炎死亡情况

2.3.2 设计思路

为了进行认真的可视化，我专注于实际死亡人数的真实分布，并在可视化中无偏差地显示出来。

对于欺骗性的可视化，为了夸大新冠肺炎疫情在美国的严重性，我故意将数据离散化，并将许多州划分为 160000 至 7900000 的范围。事实上，只有得克萨斯州的死亡人数超过 790 万，其他所有州的死亡人口都低于 33 万，近三分之二的州的死亡死亡人数低于 20 万。此外，许多州的死亡人数刚刚超过 80000 人、10000 人和 2000 人。我故意用这些数字作为垃圾桶的下限，进一步夸大美国新冠肺炎疫情的死亡人数。


2.3.3 代码

[正常代码](#) [欺骗代码](#)

2.3.4 结果展示

United States COVID-19 Deaths by State


Question: What is the situation of the COVID-19 death in all states of the United States?



United States COVID-19 Deaths by State

Data as of: Thursday, October 20, 2022 9:23 PM ET.

Question: What is the situation of the COVID-19 death in all states of the United States?



2.3.5 结论

对于认真的可视化，我们可以看到，得克萨斯州的死亡总人数远高于其他州，总人数达到约 8000000 人。其次，尽管宾夕法尼亚州、纽约州、俄亥俄州、新泽西州和弗吉尼亚州等八个州的死亡人数众多，约有 3000000 人死亡，但仍远低于德克萨斯州。最后，我们可以看到，美国大多数州的死亡人数都不到 10 万。

对于欺骗性的可视化，可以看出，只有得克萨斯州的死亡人数超过 7900000，其次是纽约州、北卡罗来纳州、新泽西州、弗吉尼亚州、田纳西州和其他 23 个州，死亡人数在 160000 至 7900000 之间。有 8 个州有 8 万至 16 万人死亡。死亡人数在 8 万至 16 万之间的州有 17 个，死亡人数在 2000 至 1 万之间的只有 5 个州，死亡人数低于 4000 的只有 3 个州。总体而言，美国人民正处于水深火热之中，新冠肺炎疫情在美国大部分州都非常严重。

三、降维

3.1 实验目标

降维是指使用某种特定的映射方法将原始高维空间中的数据点映射到低维空间。在原高维空间中，存在冗余信息和噪声信息，会在实际应用中引入误差，影响精度；而降维可以提取数据的基本结构，减少冗余信息和噪声信息造成的误差，提高应用中

的精度。

截止日期：2025.10.26

提交地址：[实验3文件夹下](#)

3.2 实验步骤

3.2.1 数据集选取

iris 数据集的中文名是安德森鸢尾花卉数据集，英文全称是 **Anderson's Iris data set**。iris 包含 150 个样本，对应数据集的每行数据。每行数据包含每个样本的四个特征和样本的类别信息，所以 iris 数据集是一个 150 行 5 列的二维表。

通俗地说，iris 数据集是用来给花做分类的数据集，每个样本包含了花萼长度、花萼宽度、花瓣长度、花瓣宽度四个特征（前 4 列），我们需要建立一个分类器，分类器可以通过样本的四个特征来判断样本属于山鸢尾、变色鸢尾还是维吉尼亚鸢尾（这三个名词都是花的品种）。

iris 的每个样本都包含了品种信息，即目标属性（第 5 列，也叫 **target** 或 **label**）。

[数据集下载](#)

3.2.3 结果展示

PCA:


- 降二维如下：

②




- 降三维如下：



②



- 使用 matlab 工具包得到推荐降维到二维:



MDS:




在工具包中推荐降至三维，可以看到绘制出来的图中很明显的发现聚成三个类，正好对应鸢尾花的三个类，每个类之间有一定的距离但是相对于 tSNE 依然存在分类和聚类不明显的缺陷

t-SNE:


- 二维效果如下:



- 三维效果如下:



- 迭代几千轮后，不论是二维还是三维，聚类结果都大致不变了 用 `scipy` 得到结果如：



可以看到，相对于 PCA 来说相似的数据离得近，不相似的数据离得远。从这两方面来讲，t-SNE 的效果要明显优于 PCA。在可视化的应用中，t-SNE 的效果要好于 PCA。

四、可视化设计-可视化相互交织的树木

4.1 实验目标

这个作业的目的是通过快速头脑风暴和草图来为新问题设计新的可视化。你的任务是制作一个可视化的相互交织的树的设计。

截止日期：2025.11.9

提交地址：[实验4文件夹下](#)

4.2 数据选取

一般的问题如下。一组节点同时包含在多个不同的树状结构中。节点可能是一棵树中的叶子，可能是另一个树中的内部节点。同一个节点可能有不同的子节点和不同的树中不同的父节点。树可能有不同的根节点。任何给定的树都不一定包含所有的节点。每个节点至少在一个树中。您应该考虑大量节点和大量树的影响。这个问题的例

子有：


- 企业可能会将其人员组织成若干个树：老板-员工层次、项目层次、办公室位置层次、电话目录结构或服务年限。
- 分类法：例如，一门关于信息可视化的课程的主题可以被组织在许多树状结构中。主题可以根据不同类型的数据空间、交互策略或视图，甚至按日历进行组织。

4.3 实验步骤

4.3.1 设计的可视化方法

首先默认所有的树都是有向无权的。箭头表示了层级关系，有箭头的那一边是子节点，另一边是父节点。所有节点一共有两种大小。当一个节点是根节点时，他的大小会比普通节点更大。不同根节点会有不同的颜色，当一个节点属于多个树，即连接了多个根节点时，他会和离自己距离最近的根节点的颜色一致。我对部门和员工的关系进行了可视化，根节点代表部门，其他节点代表员工。节点 x 是另外一个节点 y 的父节点，代表了 x 隶属于 y ，在部门 y 和员工 x 之间是代表员工属于部门 y ，而在员工 y 和员工 x 之间代表员工 y 是 x 的上级。不同部门节点拥有不同的颜色，员工节点的颜色代表离哪个部门的关系更近，即到哪个根节点的路径最短。

4.3.2 结果展示



4.3.3 实验优缺点

优点：

1. 很清晰的表达了各个节点离哪棵树的根节点最近，可以看到每个员工与哪个部门关系更密切。
2. 根节点被很醒目的表示出来了，清晰的区分了各个部门以及对应的员工。
3. 树的层级关系被清晰的表达出来，部门以及员工之间的隶属关系被明显的表现了。

缺点：

1. 当不同树的节点有较少的连接时，可视化效果较好，但是当不同树之间的节点连接数多了之后可视化将会很混乱

五、可视化网络数据

5.1 实验目标

网络数据是指在网络中传输的数据。网络数据可以指各种类型的数据，如社交网络、通信网络、引文网络、协作网络、网络图等。它们通常由节点和边组成，其中节点表示实体，边表示实体之间的关系。

截止日期：2025.11.23

提交地址：[实验5文件夹下](#)

5.2 实验步骤

5.2.1 数据集

人民的民意主要角色关系

[数据集下载](#)

5.2.2 设计思路

这幅可视化采用了力引导布局（我还添加了交互包括突出显示、拖动等，但是这里只能展示图片）。可以看到，正方人物和反方人物各自内部的联系较为紧密。欧阳菁、蔡成功、吴慧芬、吴心怡等人在这个社交网络里较为边缘，连接了较少的人；而李达康、赵立春、丁义珍、祁同伟等人则处于社交网络中心，连接了较多的人，处于社区集群的较为中心的位置。同时节点大小一定程度代表了社交影响力，可以看到祁同伟、高育良、侯亮平社交影响力较高，同时也处于社交网络中心，这些节点的入度和出度较大。

5.2.3 结果展示

人民的名义关系图谱

