

自然语言处理课程实验任务书（第一周）

实验一 人工智能基础实验——气温预测

一、实验名称

线性回归模型基础实验——基于历史数据的气温预测

二、实验目的

- 理解回归问题的基本概念及其与分类问题的区别。
- 掌握线性回归模型的基本形式及其含义。
- 学习使用 Python 与机器学习库（scikit-learn）实现线性回归模型。
- 掌握数据可视化方法，通过散点图与拟合直线分析模型效果。
- 学习常见回归评价指标，如均方误差（MSE）、平均绝对误差（MAE）和决定系数（ R^2 ）。

三、实验原理

回归（Regression）是一类用于预测连续数值的机器学习方法。在线性回归模型中，假设输入变量与输出变量之间存在线性关系，其基本形式为：

$$y = b + wx$$

其中：

- x：输入特征（例如今天的气温）
y：预测目标（例如明天的气温）
w：权重参数，表示输入变量对预测结果的影响程度
b：偏置项，用于调整模型整体位置

线性回归通过训练数据学习最合适的参数 w 和 b，使预测值与真实值之间的误差最小。

四、实验环境

Python 3.8 及以上
Jupyter Notebook 或 Python IDE
依赖库：numpy、matplotlib、scikit-learn、pandas

五、实验数据

示例数据：

今日气温 明日气温

1 2

2 3

3 4

4 6

5 5

6 7

7 8

8 9

输入特征：今日气温

预测目标：明日气温

六、实验内容

1. 数据导入与预处理
2. 构建线性回归模型
3. 使用训练数据训练模型
4. 输出模型参数
5. 使用模型进行预测
6. 可视化散点图与回归直线
7. 计算并分析模型误差

七、实验步骤

1. 导入相关库
2. 构建实验数据
3. 构建线性回归模型
4. 训练模型

5. 输出模型参数
6. 进行预测
7. 可视化回归结果
8. 计算评价指标 (MSE、MAE、 R^2)

八、实验结果分析

1. 模型得到的参数 w 和 b 分别表示什么含义?
2. 为什么回归直线不一定通过所有数据点?
3. MSE 和 MAE 的含义分别是什么?
4. 决定系数 R^2 表示什么? 其取值范围是什么?
5. 如果数据中存在异常点, 会对模型产生什么影响?

九、实验报告要求

实验报告需包含:

1. 实验目的
 2. 实验原理
 3. 实验步骤与代码
 4. 实验结果 (图表与输出)
 5. 结果分析
 6. 实验总结
-

实验二：中文分词基础实验

一、实验目的

1. 理解中文分词的基本概念及其在自然语言处理中的作用。
2. 掌握中文分词与英文分词的区别。
3. 学习使用现有中文分词工具 (如 jieba) 进行文本分词。
4. 理解中文分词中的歧义问题与未登录词问题。
5. 尝试实现一个基于词典的最大正向匹配 (FMM) 分词算法。
6. 对比不同分词方法的结果并进行分析。

二、实验原理

中文文本通常没有明显的词边界，因此需要通过分词算法将连续的汉字序列切分为词语序列。

例如：

我爱自然语言处理 → 我 / 爱 / 自然语言处理

常见的中文分词方法包括：

1. 基于词典的分词方法（如最大匹配算法）
2. 基于统计模型的方法（如 HMM、CRF）
3. 基于深度学习的方法（如 BiLSTM、BERT）

本实验主要介绍两种方法：

- （1）使用现有工具进行分词
- （2）实现最大正向匹配（Forward Maximum Matching, FMM）算法

最大正向匹配（Forward Maximum Matching, FMM）是一种基于词典的中文分词方法，其基本思想是从句子的左侧开始扫描，每次尽可能匹配词典中最长的词语，并不断向右移动，直到完成整个句子的分词。该方法利用词典中已有的词语信息，通过贪心策略选择当前能够匹配到的最长词，从而将连续的汉字序列切分为若干词语。

在具体实现过程中，首先需要统计词典中所有词语的长度，并确定其中的最大词长。随后从句子的第一个字符开始处理，根据最大词长截取一个候选字符串，并判断该字符串是否存在于词典中。如果该字符串在词典中出现，则认为匹配成功，将该词语加入分词结果，并将扫描指针向右移动该词语的长度。如果该字符串不在词典中，则将匹配长度减少一个字符，再次尝试匹配。通过不断缩短匹配长度，算法会逐步寻找较短的词语。如果匹配长度逐渐缩短到仅剩一个字符时仍然无法在词典中找到对应词语，则将当前单个字符作为一个词输出，并将指针向右移动一个字符。随后继续对剩余的字符串执行相同的匹配过程，直到整个句子被处理完成。通过这种方式，算法始终优先选择当前位置能够匹配到的最长词语，因此称为最大正向匹配。例如，对于句子“南京市长江大桥”，若词典中包含“南京”“南京市”“长江”“长江大桥”“大桥”等词语，算法首先从句子开头开始匹配，并在词典中找到“南京市”，于是输出该词并向右移动三个字符。接着对剩余字符串“长江大桥”继续匹配，并在词典中找到“长江大桥”，最终得到分词结果“南京市 / 长江大桥”。这种方法实现简单、效率较高，因此常被用作中文分词的基础算法，但由于其仅依赖词典并采用贪心策略，在遇到歧义或未登录词时可能产生错误分词。

三、实验环境

Python 3.8 及以上

Jupyter Notebook 或 Python IDE

需要安装的库：

```
pip install jieba
```

四、实验数据

实验句子示例：

我爱自然语言处理

研究生命起源

南京市长江大桥

乒乓球拍卖完了

今天天气很好

小明硕士毕业于中国科学院

实验中需要准备一个简单词典文件，例如：

我

爱

自然语言

自然语言处理

研究

生命

起源

南京

南京市

长江

长江大桥

大桥

乒乓球

乒乓球拍

拍卖

卖完了

中国科学院

五、实验内容

1. 使用 jieba 分词工具对给定句子进行分词。
2. 观察并记录分词结果。
3. 实现最大正向匹配（FMM）分词算法。
4. 使用词典对句子进行自动分词。
5. 将 FMM 分词结果与 jieba 分词结果进行比较。
6. 分析中文分词中的歧义现象。

六、实验步骤

步骤1：安装并导入 jieba 库

```
import jieba
```

步骤2：使用 jieba 进行中文分词

```
import jieba
```

```
sentences = [  
    "我爱自然语言处理",  
    "研究生命起源",  
    "南京市长江大桥",  
    "乒乓球拍卖完了"  
]
```

```
for s in sentences:  
    print("/".join(jieba.lcut(s)))
```

步骤3：实现最大正向匹配分词算法

步骤4：对比不同分词方法的结果。

七、实验结果分析

请回答以下问题：

1. 中文分词和英文分词有什么区别？

2. 为什么句子“研究生命起源”会存在不同分词方式?
3. 最大匹配算法的优点和缺点是什么?
4. 为什么词典方法难以处理未登录词?
5. jieba 分词和自实现分词结果有什么差异?
6. 三体 I 中包含多少个词? 请利用 FMM 实现分词方法, 然后进行统计。三体小说 txt 下载:
[https://github.com/VeejaLiu/ScienceFictionCollection/tree/master/001%20-%20%E5%88%98%E6%85%88%E6%AC%A3\(Cixin%20Liu\)](https://github.com/VeejaLiu/ScienceFictionCollection/tree/master/001%20-%20%E5%88%98%E6%85%88%E6%AC%A3(Cixin%20Liu))
(现代汉语词典: <https://github.com/CNMan/XDHYCD7th>)

八、实验报告要求

实验报告应包括:

1. 实验目的
2. 实验原理
3. 实验步骤与代码
4. 实验结果截图
5. 实验结果分析
6. 实验总结

提交 PDF, 并附完整代码。请将报告发送到 zyueinfosec@sdu.edu.cn。