

|                                                                                                                                                                                                                                                                                                                                                                                                       |        |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------|
| 学号：202300130183                                                                                                                                                                                                                                                                                                                                                                                       | 姓名：宋浩宇 |
| 实验名称：情感分类基础实验——文本情感极性分析                                                                                                                                                                                                                                                                                                                                                                               |        |
| <h3>1. 实验目的</h3>                                                                                                                                                                                                                                                                                                                                                                                      |        |
| <ol style="list-style-type: none"><li>理解情感分析（Sentiment Analysis）的基本概念。</li><li>掌握文本情感极性分类任务。</li><li>学习使用 Python 实现简单情感分类。</li><li>理解文本特征对情感判断的影响。</li><li>分析不同句子中的情感表达差异。</li></ol>                                                                                                                                                                                                                  |        |
| <h3>2. 实验原理</h3>                                                                                                                                                                                                                                                                                                                                                                                      |        |
| <p>情感分析是自然语言处理中的重要任务，其目标是判断文本所表达的情感倾向。</p> <p>常见情感类别包括：</p> <ul style="list-style-type: none"><li>正面（Positive）</li><li>负面（Negative）</li><li>中性（Neutral）</li></ul> <p>例如：</p> <p>这部电影很好看。 → 正面</p> <p>这个产品太差了。 → 负面</p> <p>今天天气是阴天。 → 中性</p> <p>在传统方法中，通常需要：</p> <ol style="list-style-type: none"><li>对文本进行分词</li><li>提取文本特征（如词频、TF-IDF）</li><li>使用分类模型进行预测</li></ol> <p>本实验主要采用简单文本分类方法完成情感分析任务。</p> |        |
| <h3>3. 实验步骤与代码</h3>                                                                                                                                                                                                                                                                                                                                                                                   |        |
| <p><b>实验步骤：</b></p> <ol style="list-style-type: none"><li>导入相关 Python 库</li><li>输入带标签文本数据</li><li>使用 jieba 进行分词</li><li>使用 TF-IDF 提取文本特征</li><li>构建分类模型（如朴素贝叶斯）</li><li>使用训练数据训练模型</li><li>对测试句子进行预测</li><li>输出情感分类结果</li><li>分析分类错误情况</li></ol>                                                                                                                                                      |        |
| <p><b>代码：</b></p> <pre># -*- coding: utf-8 -*- from __future__ import annotations  from pathlib import Path import jieba</pre>                                                                                                                                                                                                                                                                        |        |

```

from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.metrics import accuracy_score
from sklearn.model_selection import LeaveOneOut
from sklearn.naive_bayes import MultinomialNB
from sklearn.pipeline import Pipeline
BASE_DIR = Path(__file__).resolve().parent
DATA_PATH = BASE_DIR / "exp-9.1-data.txt"
TEST_PATH = BASE_DIR / "exp-9.1-test.txt"
def jieba_doc(text: str) -> str:
    return " ".join(jieba.cut(text.strip()))
def read_labeled(path: Path) -> tuple[list[str], list[str]]:
    texts, labels = [], []
    for raw in path.read_text(encoding="utf-8").splitlines():
        line = raw.strip()
        if not line:
            continue
        if "\t" in line:
            sent, lab = line.split("\t", 1)
        else:
            parts = line.rsplit(None, 1)
            if len(parts) != 2:
                continue
            sent, lab = parts[0], parts[1]
        texts.append(sent.strip())
        labels.append(lab.strip())
    return texts, labels
def read_lines(path: Path) -> list[str]:
    if not path.is_file():
        return []
    return [ln.strip() for ln in
path.read_text(encoding="utf-8").splitlines() if ln.strip()]
def build_clf() -> Pipeline:
    return Pipeline(
        [
            (
                "tfidf",
                TfidfVectorizer(
                    analyzer=lambda doc: doc.split(),
                    min_df=1,
                ),
            ),
            ("nb", MultinomialNB()),
        ]
    )

```

```

def main() -> None:
    print(f"训练数据: {DATA_PATH}")
    print(f"测试数据: {TEST_PATH}")
    train_x, train_y = read_labeled(DATA_PATH)
    if not train_x:
        print("训练数据为空。")
        return

    train_corpus = [jieba_doc(s) for s in train_x]
    clf = build_clf()
    clf.fit(train_corpus, train_y)
    print("\n--- 训练集预测 ---")
    pred_train = clf.predict(train_corpus)
    for sent, gold, pred in zip(train_x, train_y, pred_train):
        mark = "OK" if gold == pred else "ERR"
        print(f"{mark} | 原句: {sent} | 标签: {gold} | 预测: {pred}")

    print(f"\n 训练集准确率: {accuracy_score(train_y, pred_train):.4f}")
    print("\n--- 留一法交叉验证 ---")
    loo = LeaveOneOut()
    loo_true, loo_pred = [], []
    for tr_idx, te_idx in loo.split(train_corpus):
        x_tr = [train_corpus[i] for i in tr_idx]
        y_tr = [train_y[i] for i in tr_idx]
        x_te = train_corpus[te_idx[0]]
        y_te = train_y[te_idx[0]]
        m = build_clf()
        m.fit(x_tr, y_tr)
        p = m.predict([x_te])[0]
        loo_true.append(y_te)
        loo_pred.append(p)
        print(f"留出: {train_x[te_idx[0]]} | 真实: {y_te} | 预测: {p}")

    print(f"留一法准确率: {accuracy_score(loo_true, loo_pred):.4f}")
    test_sents = read_lines(TEST_PATH)
    if test_sents:
        print("\n--- 测试句预测 ---")
        test_corpus = [jieba_doc(s) for s in test_sents]
        pred_test = clf.predict(test_corpus)
        for sent, pred in zip(test_sents, pred_test):
            print(f"原句: {sent} | 预测: {pred}")
    vocab = clf.named_steps["tfidf"].get_feature_names_out()
    print(f"\n 特征维度: {len(vocab)}")

```

```
if len(vocab) <= 80:
    print("词表:", " ".join(vocab))
if __name__ == "__main__":
    main()
```

## 4. 实验结果（图表与输出）

输出结果为：

F:\Homework\自然语言处理作业\venv\Scripts\python.exe F:\Homework\自然语言处理作业\第九周实验\实验十七-情感分类基础实验——文本情感.py

Building prefix dict from the default dictionary ...

Loading model from cache C:\Users\23676\AppData\Local\Temp\jieba.cache

训练数据: F:\Homework\自然语言处理作业\第九周实验\exp-9.1-data.txt

测试数据: F:\Homework\自然语言处理作业\第九周实验\exp-9.1-test.txt

Loading model cost 0.373 seconds.

Prefix dict has been built successfully.

--- 训练集预测 ---

OK | 原句: 这部电影很好看。 | 标签: 正面 | 预测: 正面

OK | 原句: 这个手机太难用了。 | 标签: 负面 | 预测: 负面

OK | 原句: 老师讲课非常生动。 | 标签: 正面 | 预测: 正面

OK | 原句: 服务态度太差了。 | 标签: 负面 | 预测: 负面

ERR | 原句: 今天下雨了。 | 标签: 中性 | 预测: 负面

OK | 原句: 这本书内容很有意思。 | 标签: 正面 | 预测: 正面

训练集准确率: 0.8333

--- 留一法交叉验证 ---

留出: 这部电影很好看。 | 真实: 正面 | 预测: 正面

留出: 这个手机太难用了。 | 真实: 负面 | 预测: 正面

留出: 老师讲课非常生动。 | 真实: 正面 | 预测: 负面

留出: 服务态度太差了。 | 真实: 负面 | 预测: 正面

留出: 今天下雨了。 | 真实: 中性 | 预测: 负面

留出: 这本书内容很有意思。 | 真实: 正面 | 预测: 正面

留一法准确率: 0.3333

--- 测试句预测 ---

原句: 今天天气是阴天。 | 预测: 正面

原句: 这个电影不算差。 | 预测: 正面

原句: 这款产品的质量不是很好。 | 预测: 正面

原句: 老师讲课不算无聊。 | 预测: 正面

特征维度: 21

词表: 。 下雨 了 今天 内容 太差 太难用 好看 很 手机 有意思 服务态度 本书 生动 电影 老师 讲课 这 这个 这部 非常

进程已结束，退出代码为 0

## 5. 结果分析

### 1. 哪些句子的情感分类结果较准确？

答：在训练集上，五条句子预测与标签一致，包括“这部电影很好看。”预测正面，“这个手机太难用了。”预测负面，“老师讲课非常生动。”预测正面，“服务态度太差了。”预测负面，“这本书内容很有意思。”预测正面。这些句子都含有较明显的褒贬词，如好看、太难用、生动、太差、有意思，与标签方向一致，可视为较准确。训练集准确率为 0.8333，也主要来自上述正确样本。

### 2. 哪些句子容易出现误判？

答：训练集中“今天下雨了。”真实标签为中性，却被预测为负面，对应输出中的 ERR 行。留一法下误判更多，六句中只有两句预测与真实一致，留一法准确率为 0.3333，例如留出“这个手机太难用了。”真实负面却预测正面，留出“老师讲课非常生动。”真实正面却预测负面。测试集四句全部被预测为正面，其中“今天天气是阴天。”语义偏中性，“这款产品的质量不是很好。”含否定与弱负面，“老师讲课不算无聊。”为双重否定式，按直觉未必都应归为正面，说明中性、否定和弱情感句在本实验中较易出错。

### 3. 为什么否定词会影响情感分类结果？

答：本实验用 TF-IDF 统计词面特征，朴素贝叶斯主要依据词与类别的共现，并不理解“不”“不算”“不是很好”等对极性的翻转。例如“不是很好”仍可能出现“好”等与正面相关的字词片段，模型容易把否定结构当成普通修饰而忽略。测试句“老师讲课不算无聊。”被预测为正面，可能与“无聊”等词在训练负面句中出现、而“不算”未被建模有关。否定会改变整句极性，仅靠词袋难以稳定处理。

### 4. 情感分析为什么不仅依赖单个情感词？

答：同一情感词在不同搭配中极性不同，如“太差”偏负面而“不算差”可能偏正面。本实验训练集规模很小，词表仅 21 维，模型更多学到的是若干强情感词与类别的统计关联，而不是完整句法。若只盯单个词，“下雨”在“今天下雨了。”中被判成负面，说明模型还可能把与负面训练句共现的用字误关联到中性句。情感往往由程度副词、对比、整体叙述共同决定，需要上下文与结构信息，词袋加朴素贝叶斯对此能力有限。

### 5. 中性句子为什么较难判断？

答：中性句往往缺少强烈的褒贬词。本实验仅有一条中性训练样本“今天下雨了。”，特征上“下雨”与负面句中的情绪色彩在统计上可能被拉近，训练集上该句被预测为负面。测试句“今天天气是阴天。”也被预测为正面，与直觉上的中性不符，反映出三分类里中性类样本过少、特征不突出时，模型倾向于落入某一极性类。中性边界模糊，在词频特征下最难与正、负稳定区分。

## 6. 文本长度是否会影响情感分类效果？

答：会有影响，但本批句子都较短，长度差异不大，主要矛盾不在长短而在情感词强弱与句式。短句若只有一个强情感词，如“服务态度太差了。”在训练集上较易判对。稍长或含转折、否定的句子，如“这款产品的质量不是很好。”，词数略增却未带来更可靠的特征，反而因否定和弱情感更易误判。样本极少时，留一法准确率 0.3333 也说明数据量不足会放大长度与句式带来的不稳定，不能仅凭句长判断效果。

## 6. 实验总结

本次运行实验十七脚本，对” exp-9.1-data.txt” 六句完成” jieba” 分词、TF-IDF” 与朴素贝叶斯训练，训练集准确率” 0.8333，留一法准确率” 0.3333，并对” exp-9.1-test.txt” 四句给出预测。程序正常结束，退出代码” 0，输出含” OK/ERR” 对照、交叉验证行与” 21” 维词表。