

学号：202300130183	姓名：宋浩宇
实验名称：实验三：词性标注基础实验——基于工具的中文词性标注	
1. 实验目的	
1. 理解词性标注（POS Tagging）的基本概念。 2. 掌握中文常见词性类别。 3. 学习使用 Python 工具进行词性标注。 4. 观察词性歧义现象并分析上下文影响。 5. 理解规则方法与统计方法的差异。	
2. 实验原理	
词性标注是为每个词分配语法类别，如： 我/r 爱/v 自然语言处理/n 常见方法： 1. 规则方法 2. 统计方法（HMM、CRF） 3. 深度学习方法	
3. 实验步骤与代码	
实验步骤： 1. 导入 jieba.posseg 2. 输入句子 3. 输出词/词性 4. 对比不同句子结果	
代码： <pre>import jieba.posseg as pseg pseg.initialize() def load_exp_2_1_data(): with open("./exp-2.1-data.txt") as f: lines = f.readlines() return list(lines) if __name__ == '__main__': lines = load_exp_2_1_data() for sentence in lines: print(sentence) for word, tag in pseg.cut(sentence): print(word, tag) print()</pre>	
4. 实验结果（图表与输出）	
输出结果为： F:\Homework\自然语言处理作业\venv\Scripts\python.exe F:\Homework\自然语言处理作业\第二周实验\实验三-词性标注基础实验——基于工具的中文词性标注.py	

Building prefix dict from the default dictionary ...

Loading model from cache C:\Users\23676\AppData\Local\Temp\jieba.cache

Loading model cost 0.337 seconds.

Prefix dict has been built successfully.

我爱自然语言处理。

我 r

爱 v

自然语言 l

处理 v

。 x

x

研究生命起源很重要。

研究 vn

生命 vn

起源 n

很 zg

重要 a

。 x

x

这个问题需要深入研究。

这个 r

问题 n

需要 v

深入研究 n

。 x

x

人工智能发展很快。

人工智能 n

发展 vn

很快 d

。 x

x

他的发展方向很明确。 他 r 的 uj 发展 vn 方向 n 很 zg 明确 ad 。 x
图表结果为: 无

5. 结果分析 1. 中文分词和词性标注有什么区别？两者之间有什么关系？ 中文分词是把连续的中文文本按语义拆分成一个个独立词语的过程，只关注词语边界，而词性标注是在分词结果的基础上，给每个词语标注出它的语法类别，分词是词性标注的前提和基础，没有正确分词就无法进行准确的词性标注，词性标注则是分词之后进一步的语义与语法分析任务。 2. 在本实验中，jieba.posseg 输出的词性标签分别表示什么？请举例说明。 r 代表代词，如“我”“这个”“他”；v 代表动词，如“爱”“需要”；l 代表习语或固定短语，如“自然语言”；n 代表名词，如“起源”“问题”“方向”“人工智能”；vn 代表名动词，兼具动词和名词属性，如“研究”“生命”“发展”；zg 代表程度副词，如“很”；a 代表形容词，如“重要”；ad 代表副形词，如“明确”；d 代表副词，如“很快”；uj 代表结构助词，如“的”；x 代表标点符号，如句号，不过从结果上看，应该n 这种转义字也被认为是标点符号了。 3. 在实验过程中，是否存在词性标注结果不符合直觉的情况？请举出至少一个例子，并说明原因。 实验中存在词性标注结果不符合直觉的情况，例如“研究生命起源很重要”里的“研究”被标注为 vn，而直觉上“研究”更像动词，但在该句中它充当句子的主语成分，更偏向名词性用法，jieba 依据句法功能将其标注为名动词，因此和单纯从词义出发的直觉不一致。 4. 词性标注结果是否完全依赖单个词本身？请结合实验结果说明上下文在词性判断中的作用。 词性标注结果并不完全依赖单个词本身，上下文起到关键作用，比如“研究”在“研究生命起源很重要”中被标注为 vn，而在“这个问题需要深入研究”中，“深入研究”整体被标注为 n，“发展”在“人工智能发展很快”中标注为 vn，在“他的发展方向很明确”中同样是 vn，但所在语境不同，一个表动作进程，一个表事物状态，说明上下文的语法结构、搭配关系直接影响模型对词语词性的判断。
6. 实验总结 从结果上看，词性分析正常，jieba 还是太夯了，不过\nr 这种控制字符被按照标点符号来划分我是没想到的。