

学号：202300130183	姓名：宋浩宇
实验名称：实验四：隐马尔可夫模型词性标注实验	
1. 实验目的	
1. 理解 HMM 基本思想 2. 掌握序列标注问题 3. 学习概率建模方法 4. 理解转移概率与生成概率 5. 掌握维特比算法	
2. 实验原理	
词性标注可以看作一个序列标注问题。 给定一个词序列： 我 爱 自然语言处理 目标是预测对应的词性序列： r v n 隐马尔可夫模型（HMM）是一种常见的概率模型，其基本假设包括： 1 状态转移假设 当前词性的概率只与前一个词性有关。 $P(\text{tag}_i \text{tag}_{\{i-1\}})$ 2 观测生成假设 词语的出现只依赖于当前词性。 $P(\text{word}_i \text{tag}_i)$ 因此，一个句子的词性序列概率可以表示为： $P(T W) \propto P(W T)P(T)$ 其中：T：词性序列 W：词序列 在实际计算中，需要通过维特比算法寻找概率最大的词性序列。	
3. 实验步骤与代码	
实验步骤： 1. 读取训练语料并解析词语和词性标签 2. 统计词性转移概率 3. $P(\text{tag}_i \text{tag}_{\{i-1\}})$ 4. 统计词语生成概率 5. $P(\text{word}_i \text{tag}_i)$ 6. 构建 HMM 模型参数 7. 实现维特比算法求解最优词性序列 8. 对测试句子进行词性标注 9. 输出标注结果并分析模型效果	
代码： <pre>exp_2_2_test_sentences = ["我 学习 NLP", "人工智能 发展 很 快"]</pre>	

```

def load_exp_2_2_data():
    with open("./exp-2.2-data.txt") as f:
        lines = f.readlines()
    return lines

def get_prob(count_dict):
    total = sum(count_dict.values())
    prob = {}
    for key, cnt in count_dict.items():
        prob[key] = (cnt + 1) / (total + len(count_dict))
    return prob

class HMMModel(object):
    def __init__(self):
        pass

    def train_HMM(self, train_data):
        sentences = []
        for line in train_data:
            words_tags = []
            for item in line.split():
                word, tag = item.split("/")
                words_tags.append((word, tag))
            sentences.append(words_tags)

        from collections import defaultdict
        pi = defaultdict(int)
        A = defaultdict(lambda: defaultdict(int))
        B = defaultdict(lambda: defaultdict(int))
        for sent in sentences:
            first_word, first_tag = sent[0]
            pi[first_tag] += 1
            for i in range(len(sent)):
                word, tag = sent[i]
                B[tag][word] += 1
                if i < len(sent) - 1:
                    next_tag = sent[i + 1][1]
                    A[tag][next_tag] += 1

        pi_prob = get_prob(pi)
        A_prob = {t: get_prob(A[t]) for t in A}
        B_prob = {t: get_prob(B[t]) for t in B}
        self.pi_prob = pi_prob
        self.A_prob = A_prob
        self.B_prob = B_prob
        self.pi = pi
        self.A = A
        self.B = B

    def viterbi(self, words):

```

```

all_tags = ['r', 'v', 'n', 'p', 'd', 'a']
n = len(words)
V = [{}]
path = {}
for tag in all_tags:
    p = self.pi_prob.get(tag, 1e-5) *
self.B_prob[tag].get(words[0], 1e-5)
    V[0][tag] = p
    path[tag] = [tag]
for t in range(1, n):
    V.append({})
    new_path = {}
    for curr_tag in all_tags:
        max_p = 0
        best_prev = ''
        for prev_tag in V[t - 1]:
            trans_p = self.A_prob.get(prev_tag,
{}).get(curr_tag, 1e-5)
            emit_p = self.B_prob.get(curr_tag,
{}).get(words[t], 1e-5)
            prob = V[t-1][prev_tag] * trans_p * emit_p
            if prob > max_p:
                max_p = prob
                best_prev = prev_tag
            V[t][curr_tag] = max_p
            new_path[curr_tag] = path[best_prev] + [curr_tag]
        path = new_path
    max_prob, best_tag = max([(V[-1][tag], tag) for tag in
V[-1]])
    return path[best_tag]
if __name__ == '__main__':
    HMM = HMMModel()
    HMM.train_HMM(load_exp_2_2_data())
    result = [f"原句: {i}\n 结果: {HMM.viterbi(i.split())}" for i in
exp_2_2_test_sentences]
    for item in result:
        print(item)

```

4. 实验结果（图表与输出）

输出结果为：

F:\Homework\自然语言处理作业\venv\Scripts\python.exe F:\Homework\自然语言处理作业
 \第二周实验\实验四-隐马尔可夫模型词性标注实验.py

原句：我 学习 NLP

结果：['r', 'v', 'n']

原句：人工智能 发展 很 快 结果：['n', 'v', 'd', 'a']
图表结果为：
无

5. 结果分析 1. HMM 模型需要统计哪三类概率？分别表示什么？ HMM 模型进行词性标注需要统计初始概率、词性转移概率、发射概率三类概率，初始概率表示句子第一个词属于某一个词性的概率，词性转移概率表示从前一个词性转移到当前词性的概率，发射概率表示在某一个词性下生成对应词语的概率，这三类概率是 HMM 完成词性标注的核心统计参数。 2. 词性转移概率是如何计算的？ 统计语料中前一个词性→后一个词性出现的次数，除以前一个词性出现的总次数。 3. 发射概率表示什么？请举例说明。 发射概率表示：在给定词性时，生成某个词语的概率。比如说：词性为 r 时，生成我的概率；词性为 v 时，生成爱、学习、发展的概率；词性为 n 时，生成 NLP、自然语言处理、小明、学校、人工智能的概率。 4. $dp[i][tag]$表示什么含义？ $dp[i][tag]$表示：处理到第 i 个词，且第 i 个词的词性为 tag 时，整条路径的最大概率。 5. 为什么在计算 $dp[i][tag]$时需要遍历所有 $prev_tag$？ 因为第 i 个词的词性 tag 可以从前面任意一个词性 $prev_tag$ 转移过来，要取所有可能路径中概率最大的那一条，所以必须遍历所有 $prev_tag$。
6. 实验总结 本次实验完成了隐马尔可夫模型词性标注的实现，统计了初始概率、词性转移概率、发射概率三类参数，基于语料完成概率计算与模型构建，使用维特比算法对给定句子进行词性序列预测，输出标注结果。从最终的输出结果上来看，实验任务成功完成。