

自然语言处理第二周实验任务书

实验三：词性标注基础实验——基于工具的中文词性标注

一、实验目的

1. 理解词性标注 (POS Tagging) 的基本概念。
2. 掌握中文常见词性类别。
3. 学习使用 Python 工具进行词性标注。
4. 观察词性歧义现象并分析上下文影响。
5. 理解规则方法与统计方法的差异。

二、实验原理

词性标注是为每个词分配语法类别，如：

我/r 爱/v 自然语言处理/n

常见方法：

1. 规则方法
2. 统计方法 (HMM、CRF)
3. 深度学习方法

三、实验环境

Python 3.8+

Jupyter Notebook

依赖：jieba

pip install jieba

四、实验数据

我爱自然语言处理。

研究生命起源很重要。

这个问题需要深入研究。

人工智能发展很快。

他的发展方向很明确。

五、实验内容

1. 使用 jieba.posseg 进行词性标注
2. 输出词和词性
3. 分析歧义词
4. 观察上下文影响

六、实验步骤

1. 导入 jieba.posseg
2. 输入句子
3. 输出词/词性
4. 对比不同句子结果

七、实验结果分析

请回答以下问题：

1. 中文分词和词性标注有什么区别？两者之间有什么关系？
2. 在本实验中，jieba.posseg 输出的词性标签分别表示什么？请举例说明。
3. 在实验过程中，是否存在词性标注结果不符合直觉的情况？请举出至少一个例子，并说明原因。
4. 词性标注结果是否完全依赖单个词本身？请结合实验结果说明上下文在词性判断中的作用。

八、实验报告要求

1. 实验报告需包含：
2. 实验目的
3. 实验原理
4. 实验步骤与代码

5. 实验结果
6. 结果分析
7. 实验总结

-

实验四：隐马尔可夫模型词性标注实验

一、实验目的

1. 理解 HMM 基本思想
2. 掌握序列标注问题
3. 学习概率建模方法
4. 理解转移概率与生成概率
5. 掌握维特比算法

二、实验原理

词性标注可以看作一个序列标注问题。

给定一个词序列：

我 爱 自然语言处理

目标是预测对应的词性序列：

r v n

隐马尔可夫模型（HMM）是一种常见的概率模型，其基本假设包括：

1 状态转移假设

当前词性的概率只与前一个词性有关。

$$P(\text{tag}_i \mid \text{tag}_{\{i-1\}})$$

2 观测生成假设

词语的出现只依赖于当前词性。

$$P(\text{word}_i | \text{tag}_i)$$

因此，一个句子的词性序列概率可以表示为：

$$P(T|W) \propto P(W|T)P(T)$$

其中：T：词性序列 W：词序列

在实际计算中，需要通过维特比算法寻找概率最大的词性序列。

三、实验环境

Python 3.8+

依赖：numpy

四、实验数据

示例训练语料（已标注词性）：

我/r 爱/v NLP/n

他/r 学习/v 自然语言处理/n

小明/n 在/p 学校/n 学习/v

人工智能/n 发展/v 很/d 快/a

示例测试句子：

我 学习 NLP

人工智能 发展 很快

实验任务需要根据训练数据学习概率模型，并对测试句子进行词性标注。

五、实验内容

1. 构建简单的带词性标注训练语料
2. 统计词性转移概率
3. 统计词语生成概率
4. 构建 HMM 词性标注模型
5. 使用维特比算法计算最优词性序列
6. 输出词性标注结果并进行分析

六、实验步骤

1. 读取训练语料并解析词语和词性标签
2. 统计词性转移概率
3. $P(\text{tag}_i \mid \text{tag}_{\{i-1\}})$
4. 统计词语生成概率
5. $P(\text{word}_i \mid \text{tag}_i)$
6. 构建 HMM 模型参数
7. 实现维特比算法求解最优词性序列
8. 对测试句子进行词性标注
9. 输出标注结果并分析模型效果

伪代码框架：

输入：

训练语料 train_corpus

测试句子 test_sentence

输出：

测试句子的词性标注结果

过程：

1. 使用训练语料训练 HMM：

```
start_prob, trans_prob, emit_prob = train_HMM(train_corpus)
```

2. 取出测试句子的词序列：

```
words = test_sentence.split()
```

3. 使用维特比算法解码：

```
best_tags = viterbi(words, start_prob, trans_prob, emit_prob)
```

4. 输出结果：

对每个词 words[i]：

输出 words[i] / best_tags[i]

七、实验结果分析

HMM 模型需要统计哪三类概率？分别表示什么？

词性转移概率是如何计算的？

发射概率表示什么？请举例说明。

dp[i][tag] 表示什么含义？

为什么在计算 dp[i][tag] 时需要遍历所有 prev_tag？

八、实验报告要求

1. 实验报告需包含：

2. 实验目的

3. 实验原理

4. 实验步骤与代码
5. 实验结果
6. 结果分析
7. 实验总结

请将实验发送到, yz_xu@mail.sdu.edu.cn 邮件标题: 姓名-学号-自然语言处理第二周实验。报告为PDF。两份报告放到同一邮件中。