

学号：202300130183	姓名：宋浩宇
实验名称：统计机器翻译基础实验——基于词典与规则的中英文翻译	
1. 实验目的	
1. 理解机器翻译（Machine Translation）的基本概念。 2. 掌握基于规则和词典的简单翻译方法。 3. 学习使用 Python 实现简单中英文翻译。 4. 理解词语顺序对翻译结果的影响。 5. 分析规则翻译方法的局限性。	
2. 实验原理	
机器翻译的目标是将一种自然语言自动转换为另一种自然语言。 例如： 我 爱 自然语言处理 I love natural language processing 传统机器翻译方法通常依赖： 1. 双语词典 2. 语法规则 3. 词序调整 在最简单的规则翻译中： - 先进行分词 - 再查找词典 - 最后按照目标语言顺序进行组合 例如： 我 -> I 爱 -> love 苹果 -> apple 本实验通过构建简单的中英文词典，实现基础翻译系统。	
3. 实验步骤与代码	
实验步骤： 1. 构建中英文词典 2. 输入中文句子 3. 使用 jieba 进行中文分词 4. 查找词典对应英文单词 5. 按顺序组合英文句子 6. 输出翻译结果 7. 对多个句子进行测试 8. 分析翻译中的问题	
代码： <pre>from __future__ import annotations from pathlib import Path import jieba</pre>	

```

BASE_DIR = Path(__file__).resolve().parent
DATA_PATH = BASE_DIR / "exp-8.1-data.txt"
# 任务书示例词典(键为中文词或短语, 值为英文; 多字短语优先于单字)
ZH_EN_DICT: dict[str, str] = {
    "我": "I",
    "你": "You",
    "爱": "Love",
    "学习": "Study",
    "自然语言处理": "NLP",
    "苹果": "Apple",
}

DEFAULT_SENTENCES = [
    "我爱自然语言处理。",
    "你学习人工智能。",
    "我爱苹果。",
]

def register_dict_for_jieba() -> None:
    """将词典中的词组注册到 jieba, 减少多字词条被错误切开的情况。"""
    for phrase in sorted(ZH_EN_DICT.keys(), key=len, reverse=True):
        jieba.add_word(phrase, freq=10**9)

def read_sentences(path: Path) -> list[str]:
    if not path.is_file():
        return list(DEFAULT_SENTENCES)
    out: list[str] = []
    for raw in path.read_text(encoding="utf-8").splitlines():
        s = raw.strip()
        if s:
            out.append(s)
    return out if out else list(DEFAULT_SENTENCES)

def translate_sentence(sentence: str, unk_template: str = "[未登录:{word}]") -> tuple[str, list[str], list[str]]:
    tokens = list(jieba.cut(sentence.strip()))
    pieces: list[str] = []
    en_parts: list[str] = []
    for tok in tokens:
        if tok.strip() == "":
            continue
        # 纯标点原样略过或保留: 此处跳过空白与常见句末标点, 便于阅读
        if all(not ch.isalnum() and ch not in ZH_EN_DICT for ch in tok):
            continue
        en = ZH_EN_DICT.get(tok)
        if en is None:
            en = unk_template.format(word=tok)

```

```

        pieces.append(tok)
        en_parts.append(en)
    return " ".join(en_parts), pieces, en_parts
def main() -> None:
    register_dict_for_jieba()
    print(f"数据文件: {DATA_PATH}")
    print(f"词典条目数: {len(ZH_EN_DICT)}")
    print("\n--- 当前中英词典(中文 -> 英文)---")
    for zh in sorted(ZH_EN_DICT.keys(), key=lambda s: (-len(s), s)):
        print(f"    {zh} -> {ZH_EN_DICT[zh]}")
    sentences = read_sentences(DATA_PATH)
    print(f"\n{'=' * 14} 翻译结果 {'=' * 14}")
    for i, sent in enumerate(sentences, 1):
        en_line, toks, en_tok = translate_sentence(sent)
        print(f"\n--- 句子 {i} ---")
        print(f"原文: {sent}")
        print(f"jieba 分词: {' / '.join(toks)}")
        print(f"逐词译文片段: {' | '.join(en_tok)}")
        print(f"组合英文: {en_line}")
if __name__ == "__main__":
    main()

```

4. 实验结果（图表与输出）

输出结果为：

```

F:\Homework\自然语言处理作业\venv\Scripts\python.exe F:\Homework\自然语言处理作业
\第八周实验\实验十五-统计机器翻译基础实验——基于词典与规则的中英文翻译.py
Building prefix dict from the default dictionary ...
Dumping model to file cache C:\Users\23676\AppData\Local\Temp\jieba.cache
数据文件: F:\Homework\自然语言处理作业\第八周实验\exp-8.1-data.txt
词典条目数: 6

--- 当前中英词典（中文 -> 英文）---
自然语言处理 -> NLP
学习 -> Study
苹果 -> Apple
你 -> You
我 -> I
爱 -> Love

===== 翻译结果 =====

--- 句子 1 ---
原文: 我爱自然语言处理。
jieba 分词: 我 / 爱 / 自然语言处理

```

逐词译文片段: I | Love | NLP

组合英文: I Love NLP

--- 句子 2 ---

原文: 你学习人工智能。

jieba 分词: 你 / 学习 / 人工智能

逐词译文片段: You | Study | [未登录:人工智能]

组合英文: You Study [未登录:人工智能]

--- 句子 3 ---

原文: 我爱苹果。

jieba 分词: 我 / 爱 / 苹果

逐词译文片段: I | Love | Apple

组合英文: I Love Apple

Loading model cost 0.361 seconds.

Prefix dict has been built successfully.

5. 结果分析

1. 哪些句子的翻译结果较准确?

第 1 句和第 3 句相对更准确。两句的分词结果（我、爱、自然语言处理 与 我、爱、苹果）里的词都在词典中，英文片段依次为 I、Love、NLP 以及 I、Love、Apple，没有出现未登录标记，语义上也能大致对上原意。

2. 哪些句子存在翻译错误?

第 2 句存在明显问题。分词得到 你、学习、人工智能，其中 人工智能 不在词典里，输出里出现了 [未登录:人工智能]，整句英文变成 You Study 加上未登录占位，读者无法从英文得到“人工智能”的含义，属于翻译失败或不完整。第 1、3 句若按地道英文标准，仍可能有大小写、冠词、语体等不足，但就你这次程序规则而言，主要错误集中在第 2 句的未登录词。

3. 中文与英文词序是否完全一致?

就本次“按分词顺序逐段拼接”的做法而言，三个中文片段与三个英文片段是一一按顺序对齐的，所以片段顺序一致。但不能据此认为中文与英文“词序完全一致”，因为英文里语序、成分位置、修饰关系常与中文不同，本程序也没有做任何句法调序，只是碰巧这三句较短，顺序读起来还不算太离谱。

4. 为什么仅依赖词典无法实现高质量翻译?

词典只能做词或短语的局部替换，缺少句法分析、语义消歧、搭配与习语处理、省略与指代、时态体貌、冠词与介词等英语形态句法信息，也无法根据上下文选义。像第 2 句一旦出现词典外的词，系统就没有生成合理译文的机制，整体质量会受上限约束。

5. 未登录词会对翻译产生什么影响?

未登录词无法映射到目标语，程序用占位符标出，目标句中会出现缺口或噪声，信息丢失，句子不自然、不可用。你这次第 2 句的 [未登录:人工智能] 就是典型表现，后半段语义在

英文里基本缺失。

6. 规则翻译相比大模型翻译有哪些局限性？

1) 翻译结果强依赖于分词器的结果。2) 翻译结果强依赖于词典设计。3) 无法应对一词多义或者固定搭配。4) 无法应对特殊句式比如倒装句等。

6. 实验总结

本次在本地用 `jieba` 对任务书中的三句中文分词，再按给定中英词典做逐词替换并顺序拼接英文。程序已正常跑通，第 1、3 句各词均在词典内，得到 `ILoveNLP` 与 `ILoveApple` 等可读输出。第 2 句中人工智能未在词典中，英文里出现未登录占位，体现了纯词典规则翻译的覆盖上限。输出格式便于对照分词与译文片段，符合“规则加词典”的演示目的。