

学号：202300130183	姓名：宋浩宇
实验名称：实验八：命名实体识别基础实验——实体级语义分析	
1. 实验目的	
- 理解命名实体识别（NER）的基本概念。 - 掌握常见实体类别（人名、地名、机构名等）。 - 学习使用 NLP 工具进行实体识别。 - 能够分析识别错误和遗漏现象。 - 理解实体识别在语义分析中的作用。	
2. 实验原理	
命名实体识别（NER）是从文本中识别具有特定意义的实体并进行分类。 例如： 张三 在 北京大学 学习。 实体包括： 张三（人名） 北京大学（机构） 常见方法： - 基于规则方法 - 基于统计模型（HMM、CRF） - 基于深度学习（BERT 等）	
3. 实验步骤与代码	
实验步骤： - 安装并导入 NLP 工具 - 输入实验句子 - 调用实体识别接口 - 输出实体及类别标签 - 对比不同句子结果 - 记录错误情况 - 分析原因	
代码： <pre># -*- coding: utf-8 -*- import jieba.posseg as pseg DATA_PATH = r"./exp-4.2-data.txt" # jieba 词性 → 实体类别说明(常见专名/时间/数词) TAG_TO_ENTITY = { "nr": "人名", "ns": "地名", "nt": "机构名", "nz": "其它专名", "t": "时间", "m": "数词",</pre>	

```

    "eng": "英文专名",
    "x": "字符串/符号",
}
def read_sentences(path):
    with open(path, "r", encoding="utf-8") as f:
        return [line.strip() for line in f if line.strip()]
def extract_entities(sentence):
    """返回 [(词, 词性, 实体类别说明), ...]"""
    out = []
    for word, flag in pseg.cut(sentence):
        if flag in TAG_TO_ENTITY:
            out.append((word, flag, TAG_TO_ENTITY[flag]))
    return out
def print_sentence_ner(idx, sentence):
    print(f"\n=== 句{idx}: {sentence}")
    entities = extract_entities(sentence)
    if not entities:
        print("(未识别到专名类词性实体, 可结合报告分析漏识别)")
        return
    print("实体\t词性\t类别")
    for word, flag, desc in entities:
        print(f"{word}\t{flag}\t{desc}")
def main():
    pseg.initialize()
    sentences = read_sentences(DATA_PATH)
    print("===== 命名实体识别(jieba 词性) =====")
    for i, sent in enumerate(sentences, 1):
        print_sentence_ner(i, sent)
if __name__ == "__main__":
    main()

```

4. 实验结果（图表与输出）

输出结果为：

F:\Homework\自然语言处理作业\venv\Scripts\python.exe F:\Homework\自然语言处理作业\第四周实验\实验八-命名实体识别基础实验——实体级语义分析.py

Building prefix dict from the default dictionary ...

Loading model from cache C:\Users\23676\AppData\Local\Temp\jieba.cache

Loading model cost 0.336 seconds.

Prefix dict has been built successfully.

===== 命名实体识别（jieba 词性） =====

==== 句 1: 张三在北京大学学习。

实体	词性	类别
张三	nr	人名
在	p	
北京	ns	地名
大学	ns	地名
学习	vn	

张三 nr 人名 北京大学 nt 机构名 。 x 字符串/符号 == 句 2: 李雷来自山东济南。 实体 词性 类别 李雷 nr 人名 山东 ns 地名 济南 ns 地名 。 x 字符串/符号 == 句 3: 华为公司发布了新产品。 实体 词性 类别 华为公司 nt 机构名 。 x 字符串/符号 == 句 4: 2025 年 3 月 15 日王老师在上海开会。 实体 词性 类别 2025 m 数词 年 m 数词 3 m 数词 月 m 数词 15 m 数词 日 m 数词 王老师 nr 人名 上海 ns 地名 。 x 字符串/符号 == 句 5: OpenAI 发布了新模型。 实体 词性 类别 OpenAI eng 英文专名 。 x 字符串/符号	
图表结果为: <table><tr><td>无图表结果</td></tr></table>	无图表结果
无图表结果	
5. 结果分析 1.识别出了哪些实体类型 本次输出里有人名、机构名、地名、数词、英文专名，以及被标成字符串类的句末标点。人名对应张三李雷王老师，机构名对应北京大学华为公司，地名对应山东济南上海，数词主要出现在第四句的日期片段，英文专名对应 OpenAI。 2.哪些句子识别效果较好 第一句人名和机构名边界清楚，第二句人名和两级地名分开标出，第三句机构名整段连续，第五句英文专名整块标出，这几句主要实体与任务书预期一致。第四句除日期外人名和上海	

地名也对，但整体最杂乱。

3. 哪些实体识别错误或遗漏

第四句日期没有被当作一个整体时间实体，而是拆成多个数词，年月日相关单字也标成数词，不便于当作一条日期实体使用。句末标点被当成字符串类实体输出没有语义价值，属于噪声。其余句里任务书关心的主要专名没有明显遗漏。

4. 为什么机构名和地名容易混淆

机构名里常含地名成分，模型在边界和类别上区分不硬，长机构名或带地名的牌子容易在机构与地名之间摇摆。本次样例里北大为机构山东济南为地名尚未混用，复杂文本里仍可能出现标错。

5. 英文实体如 OpenAI 识别效果如何

本句中 OpenAI 整体标为英文专名，效果正常。更长的英文或中英混写时切分和类别仍可能不稳，需要更多句子再判断。

6. 实验总结

对五条例句做分词和词性筛选并打印实体，主要人名机构地名和 OpenAI 均能对应输出，第四句日期被拆散、句末标点被误列为实体，实验已按要求完成并记录。