

自然语言处理第四周实验任务书

实验七：词义相似度基础实验

一、实验名称

词义相似度基础实验——基于词向量的语义相似度计算

二、实验目的

1. 理解语义分析的基本概念及其与词汇分析的区别。
2. 理解词语语义相似度的含义及其计算方法。
3. 掌握词向量 (Word Embedding) 的基本思想。
4. 学习使用 Python 工具 (gensim) 计算词语相似度。
5. 能够分析不同词语之间的语义关系是否符合直觉。

三、实验原理

语义分析关注语言单位的“意义”及其关系。词语之间不仅有形式差异，还存在语义距离。

例如：“高兴”和“快乐”语义接近，而“高兴”和“悲伤”语义相反。

词向量方法将词语表示为向量，使语义相似的词在向量空间中距离更近。

常用相似度计算方法：

1. 余弦相似度：衡量两个向量夹角
2. 欧氏距离：衡量空间距离

本实验通过词向量计算词语之间的相似度，并分析结果。

四、实验环境

Python 3.8 及以上

Jupyter Notebook 或 Python IDE

依赖库：

gensim

numpy

scikit-learn

安装：

```
pip install gensim numpy scikit-learn
```

五、实验数据

示例词对：

国王 - 皇后

苹果 - 香蕉

老师 - 学生

汽车 - 火车

高兴 - 快乐

高兴 - 悲伤

北京 - 中国

猫 - 桌子

六、实验内容

1. 加载预训练词向量或训练简单词向量模型

2. 获取词语的向量表示
3. 计算词语之间的余弦相似度
4. 输出不同词对的相似度
5. 比较语义相近与无义词的差异
6. 分析结果是否符合语义直觉

七、实验步骤

1. 导入相关库（gensim、numpy 等）
2. 加载词向量模型（或训练简单模型）
3. 输入待比较的词对
4. 获取词向量表示
5. 计算余弦相似度
6. 输出相似度结果
7. 对结果进行排序和分析

八、实验结果分析

1. 哪些词对的相似度较高？哪些较低？
2. 结果是否符合语义直觉？请举例说明。
3. 为什么“高兴-快乐”比“高兴-悲伤”相似度更高？
4. 为什么“北京-中国”相似但不完全相同？
5. 是否存在不符合直觉的结果？可能原因是什么？

九、实验报告要求

实验报告需包含：

1. 实验目的
2. 实验原理

3. 实验步骤与代码

4. 实验结果（相似度输出）

5. 结果分析

6. 实验总结

实验八：命名实体识别基础实验——实体级语义分析

一、实验名称

命名实体识别基础实验——基于工具的中文实体识别

二、实验目的

1. 理解命名实体识别（NER）的基本概念。
2. 掌握常见实体类别（人名、地名、机构名等）。
3. 学习使用 NLP 工具进行实体识别。
4. 能够分析识别错误和遗漏现象。
5. 理解实体识别在语义分析中的作用。

三、实验原理

命名实体识别（NER）是从文本中识别具有特定意义的实体并进行分类。

例如：

张三 在 北京大学 学习。

实体包括：

张三（人名）

北京大学（机构）

常见方法：

1. 基于规则方法
2. 基于统计模型（HMM、CRF）
3. 基于深度学习（BERT 等）

四、实验环境

Python 3.8 及以上

Jupyter Notebook 或 Python IDE

依赖库：

jieba / hanlp（任选）

安装：

```
pip install jieba
```

五、实验数据

示例句子：

张三在北京大学学习。

李雷来自山东济南。

华为公司发布了新产品。

2025 年 3 月 15 日王老师在上海开会。

OpenAI 发布了新模型。

六、实验内容

1. 导入实体识别工具
2. 对句子进行实体识别
3. 输出实体及其类别
4. 分析不同句子的识别结果
5. 观察错误识别和漏识别
6. 总结实体识别特点

七、实验步骤

1. 安装并导入 NLP 工具
2. 输入实验句子
3. 调用实体识别接口
4. 输出实体及类别标签
5. 对比不同句子结果
6. 记录错误情况
7. 分析原因

八、实验结果分析

1. 识别出了哪些实体类型？
2. 哪些句子识别效果较好？
3. 哪些实体识别错误或遗漏？
4. 为什么机构名和地名容易混淆？
5. 英文实体（如 OpenAI）识别效果如何？

九、实验报告要求

实验报告需包含：

1. 实验目的
2. 实验原理
3. 实验步骤与代码
4. 实验结果（实体识别结果）
5. 结果分析
6. 实验总结

请将实验发送到：yz_xu@mail.sdu.edu.cn

邮件标题：姓名-学号-自然语言处理第三周实验。报告为 PDF。两份报告放到同一邮件中。